

Sistema Recomendador con Switching en Base de Datos con Ítems Únicos

Matías Aedo (meaedo@uc.cl),
Sofía Olmedo (sofia.olmedo.s@uc.cl),
Sebastián Veliz (saveliz@uc.cl)

Abstract: Existen diversos modelos de sistemas recomendadores con mejores rendimientos en determinadas situaciones, un Sistema recomendador con Switching permite el uso de estos modelos en distintas situaciones de forma automática para mejorar las recomendaciones. Se trabaja con la base de datos de un e-commerce de re-sale con ítems de stock único (sólo una persona puede comprar un ítem). Se propone un sistema recomendador con un switch integrando “random”, una clase de “most popular” y content-based RecSys según el uso específico de cada usuario de la tienda. El content-based se basa en las características percibidas de cada prenda, información ya presente en la base de datos. Los resultados obtenidos presentan un buen rendimiento en comparación a la “*baseline*” que se tiene, la cual es el sorting default actual de Vestuá, el e-commerce en cuestión. Sin embargo, queda espacio para mejorar, y se proponen ideas a implementar como trabajo a futuro.

Keywords: Switching Recommender; Collaborative Filtering; Diversidad; Unique Stock Item Dataset.

Introducción

Contexto

En la industria de la moda se ha visto un auge en una tendencia que parece no disminuir: el re-sale. Esto consiste en la compra y venta de prendas y artículos de segunda mano. Según Retail Leader [1], para el 2026 el mercado del re-sale va a haber crecido un 127%, 3 veces más rápido de lo que crece el retail.

Sin embargo, el re-sale se encuentra con varios problemas a lo largo del camino si se desea llegar a alcanzar una industria masiva. Como la opinión pública sobre la ropa usada ha mejorado considerablemente en estos últimos años, el principal problema actualmente es el manejo del stock, ya que en su mayoría consiste de prendas únicas. Para este proyecto, el

enfoque se centrará en una start-up chilena que se encuentra en el centro del mundo del re-sale: Vestuá [2]. Este es un e-commerce de ropa femenina de segunda mano. La ropa que muestran es otorgada por usuarias que “donan” ropa por una posible comisión si ésta es aceptada para la venta. A través de los años, Vestuá ha conseguido un crecimiento constante y fuerte, ganando el favor de grandes tiendas nacionales e internacionales [3]. Lo que se traduce en más clientas y un catálogo mucho más extenso. Sin mencionar, por el auge del re-sale en Chile, más competencia.

Problema

En la competencia de re-sale versus retail (tomando en cuenta la venta masiva y no boutique), el primero se encuentra en una gran desventaja al momento de captar la atención de su clientela: su stock consta principalmente de prendas únicas. Esto incluye detalles como tallas, estado de las prendas, etc. Por esto, en la personalización del catálogo según los gustos del usuario, el retail se ve en una posición mucho más ventajosa, ya que al tener artículos con posibilidad de ser consumidos por múltiples usuarios, los sistemas recomendadores a implementar pueden generar una recomendación mucho más precisa y llamativa.

Vestuá consta de un catálogo mucho más extenso que antes y una clientela más variada, lo que le dificulta a la tienda para poder mostrar productos que llamen la atención de todas las usuarias. Generando así un *conversion-rate* con muchas posibilidades de mejora. Esto se podría solucionar con un sistema de recomendación personalizado, pero ahí entra el problema mencionado inicialmente: los productos son de consumo único, por lo que no se tienen datos previos del posible interés de compra generado por una prenda en diferentes usuarias, ya que no se pueden comprar por más de una persona.

Estado del Arte

Intentos de recomendaciones internos

Vestúa es consciente de los beneficios que trae un buen sistema de recomendación, por lo que se han intentado implementar diferentes estrategias de orden para el catálogo como una forma básica de sistema recomendador, ya que los primeros productos se pueden considerar como los productos “recomendados” a la usuaria. Hasta ahora, todos los órdenes implementados han sido no personalizados. A continuación se hará un listado en orden cronológico de los distintos órdenes implementados en el catálogo:

- **Recientes:** Esta fue la primera forma de ordenar los productos, apelando al factor de novedad que conlleva ver productos nuevos al comienzo del catálogo. Este fue reemplazado como sistema principal ya que no se hacía una diferencia entre los productos en relación a las interacciones entre las usuarias y los productos.
- **CTR:** Este fue el primer intento de orden por interacción buscando un “most popular”, tomando como el puntaje de cada producto como *clicks/impressions* donde *clicks* son las veces que se accedió a la página de detalle de un producto, e *impressions* son las veces que este se vio en el catálogo. Esta iteración de orden no funcionó de la manera esperada ya que, aparentemente, los clicks no presentaban correlación con el gusto de una clienta por un producto
- **Favoritos:** En esta iteración, se recomendó por el número de favoritos que tenía una prenda. Este intento demostró ser exitoso, por lo que se pudo ver una correlación entre los favoritos y la intención de comprar de las usuarias. Sin embargo, por falta de novedad, este tuvo que ser reemplazado. Ya que siempre se mostraban los mismos productos, era difícil que otros llegaran a sobrepasar a los principales en favoritos.
- **Wilson Score:** Esta es la iteración actual de la recomendación “Most Popular”. Se utiliza el Wilson Score para obtener cotas upper y lower con el número de favoritos que tiene una prenda como caso favorable, y número de impresiones como casos
- totales. Esta ha demostrado tener un balance entre novedad y calidad en el catálogo aceptado favorablemente por las usuarias, como se puede ver en el estudio realizado por la compañía en Google Optimize (Figura 1.)




Figura 1. Experimento de direccionamiento selectivo a catálogos ordenados con las diferentes métricas. Eje X: tiempo. Eje Y: porcentaje de posibilidad de superar interacciones según una base. “Wilson Score” en amarillo, “Nº de Favoritos” en celeste, y “Más Recientes” en gris.

Estado del Arte Externo

Los sistemas recomendadores content-based tienen cualidades útiles al momento de encontrarse con un problema así [4], destacando que no es necesaria la información de otros usuarios para recomendar ítems para un usuario específico. El método relevante para esto consiste en separar el producto en un vector de características, y recomendar productos cuya distancia sea pequeña en relación al vector promedio de los productos utilizados para generar la recomendación. Esta es una técnica común debido a su simpleza. Sin embargo, actualmente existen métodos de recomendación content-based basados en redes neuronales [5]. Aprovechando así la última tecnología disponible.

Para separar un ítem en características existen distintas tecnologías de reconocimiento de imágenes. En este caso, se menciona “VueTag”[6], la cual tiene un servicio para e-commerce, el cual ve imágenes con una calificación simple (por ejemplo: “Vestido”), y genera tags descriptivos de este producto. Esta herramienta es utilizada actualmente por Vestuá para catalogar y categorizar sus productos.

En cuanto a Switching Recommenders, se han realizado pocos acercamientos y en general apuntan a utilizar sistemas híbridos, para mejorar las recomendaciones en base a una recomendación previa con un modelo [7][8], lo que puede obligar a necesitar una mayor cantidad de información de la que está presente en cierto punto del desarrollo de una startup

Dataset

Para el proyecto se utilizaron datos extraídos de la base de datos de la empresa. Se obtuvieron solamente los necesarios para realizar este experimento, protegiendo así la identidad de los usuarios de la página. El *dataset* obtenido se agrupa en cinco *dataframes* diferentes, que describen las ventas realizadas en el sitio y los elementos que se pueden asociar a estas.

En primer lugar, se tiene un *dataframe* de los productos, este tiene un total de 39152 filas y 11 columnas. Dentro de las columnas disponibles se encuentran un id único del producto, el nombre y atributos que permiten describir el producto, como talla, color, entre otros.

En segundo lugar, se tiene un *dataframe* de las ventas realizadas, este tiene un total de 3000 filas y 4 columnas. Estas son, un id único por venta, un *timestamp* de la venta, el identificador de la usuaria que realiza la compra y una lista con los productos.

En tercer lugar, se tiene un *dataframe* con las interacciones de las usuarias con los productos, este tiene un total de 3266 filas y 5 columnas. Estas son, un identificador único de la interacción, el id del producto, los *clicks*, impresiones y favoritos que se asocian al producto.

En cuarto lugar, se tiene un *dataframe* asociando uno-a-uno un producto con un tag específico. Esta tiene un total de 355002 filas y 2 columnas. Ambas identificadoras: una del producto, y otra del tag asociado a este.

Por último, se tiene un *dataframe* con las etiquetas que describen los atributos de los productos, este tiene un total de 753 filas y 3 columnas. Estas son, un identificador único para la etiqueta, una descripción y el tipo de etiqueta.

Solución

Se plantea un sistema Switching Recommender en base a la cantidad de transacciones disponibles y que ha realizado el usuario. Esto con la finalidad de disminuir el impacto del cold-start y mejorar el rendimiento en métricas distintas a las de ranking. Además se optimiza el tiempo de ejecución dependiendo de la información disponible, evitando utilizar sistemas complejos para situaciones que no lo ameritan.

Un Switching Recommender varía en el modelo a utilizar según ciertas situaciones definidas

de acuerdo a las necesidad. En este caso se definen las siguientes situaciones con sus modelos respectivos:

- 0 interacciones en la tienda:
 - Random: Se entregan 5 productos al azar para cualquier usuario
- 1 o más interacciones en la tienda:
 - Usuario sin compras:
 - Most popular: Se entregan 5 recomendaciones en base a los productos con más favoritos
 - Usuario con 1 o más compras:
 - Most popular personalizado: Se utilizan las tallas para filtrar los productos populares.
 - Usuario con 5 o más compras:
 - Collaborative Filter Unitary: Se recomiendan productos cuyos vectores se encuentran cercanos al promedio de los vectores de características de cada producto.
 - Usuario con más de 10 compras:
 - Collaborative Filter Múltiple: Se utilizan 3 puntos en el espacio de productos y se recomienda un sample aleatorio de productos cercanos a alguno de estos centros.

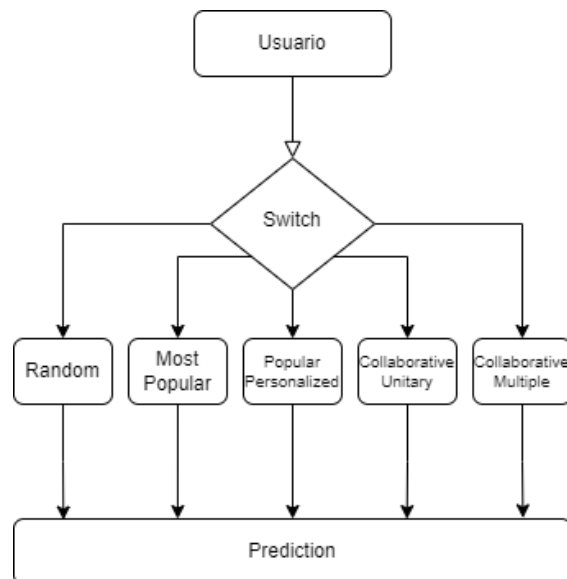


Figura 2. Representación gráfica del sistema de switching implementado, con los 5 modelos recomendadores que se utilizan bajo las situaciones definidas anteriormente.

Metodología

Se realizó un análisis de los datos obtenidos, para conocer su estructura y determinar la utilidad de estos. En este proceso se encontraron distintas dificultades dada la naturaleza del

dataset. Por lo que se decidió realizar supuestos que permitieran utilizar todos los datos en conjunto. Se determinó qué datos y cómo usarlos para generar una matriz de características efectivas. Esta fue reducida de 600 columnas a 60. Debido a que la información era inconsistente, se realizó limpieza de datos para que toda la información a utilizar siga la misma estructura definida. Para la limpieza se modificaron aquellos productos con la información necesaria dispersa y se eliminaron aquellos productos que no contaban con la información necesaria en ninguna columna. Del mismo modo se realizó la revisión y limpieza correspondiente con todos los datasets.

Luego se realizó una recopilación de información para tener los datos necesarios con fácil acceso. Para esto se tomó una muestra de 200 clientes distintos y así tener una muestra representativa del dataset. Se obtuvieron los productos que han comprado estos clientes seleccionados a partir de las transacciones realizadas. Finalmente se obtuvieron los *Popularity Insights* y *Tags* asociados a los productos seleccionados.

Una vez extraídos todos los datos necesarios, se analizó el rendimiento de distintos modelos de recomendación para obtener su rendimiento por separado y evaluar la factibilidad de integrarlo al sistema de Switch.

Con los modelos de recomendación seleccionados, se procede a integrarlos en la estructura del Switch, dependiendo de las situaciones mencionadas anteriormente con la finalidad de que el cambio entre estos se realice de forma automática según las características e información que se tenga del cliente y de la tienda.

Finalmente se evaluó utilizando 3 métricas relevantes para la finalidad de este sistema recomendador. Estas son Intra-List Similarity, Personalization y Correctness. Con esto se procede a analizar los resultados obtenidos. Además se utilizaron distintas cantidades de elementos a recomendar para determinar cuándo se recomendaban elementos que estaban lejos de lo que buscaba el usuario.

Análisis de Parámetros

En el modelo implementado existen dos áreas con parámetros a analizar: el sistema recomendador en sí, y las reglas del switching:

Sistema Recomendador:

En este caso, debido a la naturaleza del sistema recomendador implementado, el único parámetro variable es la cantidad de productos recomendados. Se puede ver en la sección de resultados que se experimentó variando el número de productos recomendados, obteniendo resultados extremadamente similares entre sí. Debido a esto, y a que no se le quiere dar una

ventaja innecesaria al baseline, se decidió que el número de productos recomendados por default sea 10.

Condiciones de Switch:

Debido a la falta de literatura al respecto, y a no ser el foco exacto del sistema recomendador, se decidió aplicar condiciones manuales para el switch siguiendo una lógica aceptada por el equipo. A continuación se listan estos parámetros y la lógica que llevó a escogerlos:

- 0 interacciones en la plataforma y usuario con 0 compras: Este es el único parámetro no-subjetivo, ya que representa el caso base. En este caso no se puede aplicar ningún sistema recomendador ya que no se tienen datos ni del contenido ni del usuario.
- Interacciones mayor o igual a 1 y usuario con 0 compras: Esta cota fue escogida ya que, si bien no se puede basar una recomendación en las compras realizadas por la usuaria, ya se tiene información sobre interacciones con los productos. Esto es información no presente previamente.

Los siguientes pasos considerarán que la página presenta interacciones previas.

- Usuario con compras mayor o igual a 1 y menor a 5: Esta cota fue definida por el equipo intentando representar un usuario que ha interactuado con la página, pero no lo suficiente como para tener un entendimiento profundo de sus gustos. En palabras simples, este sería un “usuario nuevo”.
- Usuario con compras mayor o igual a 5 y menor a 10: Esta cota fue definida por el equipo intentando representar un usuario del cual ya se puede obtener información básica sobre las preferencias de este mismo. En palabras simples, este sería un “usuario casual”.
- Usuario con compras mayor o igual a 10: Esta cota fue definida tratando de representar al usuario que ya presenta claras tendencias de las cuales se pueden generar múltiples recomendaciones. Sería, en palabras simples, un “usuario frecuente”.

Resultados

Se utilizan métricas para medir lo siguiente:

- Intra-list Similarity: Permite conocer el grado de diversidad que tienen las recomendaciones realizadas para un mismo usuario, entre sí. En este caso se busca un valor más cercano a 0.
- Correctness: Función que evalúa si el producto recomendado fue efectivamente comprado por el cliente utilizando ground truth

- Personalization: Determina qué tan únicas son las recomendaciones para cada usuario con respecto al resto de recomendaciones.

	Wilson Score (k=10)	Wilson Score (k=20)	Wilson Score (k=30)	Switch (k=10)	Switch (k=20)	Switch (k=30)
Correctness	0,02	0,02	0,03	0,133	0,133	0,121
Intra-list Similarity	0,09	0,103	0,111	0,292	0,390	0,295
Personalization	~0	~0	~0	0,959	0,965	0,968

Figura 3. Tabla comparativa de resultados obtenidos según distintas métricas entre el baseline y el modelo desarrollado con variación de número de recomendaciones (k).

En base a los resultados obtenidos se pudo determinar que el sistema desarrollado obtiene mejores resultados en 2 de las métricas.

Para el caso de correctness, se aprecia que alrededor de 1 de cada 10 elementos recomendados estarían potencialmente dentro de las compras de la cliente, frente a los 2 de cada 100 del baseline.

En cuanto a personalización, dado que Wilson Score tiene un funcionamiento dependiente de un Insight que no depende de cada usuario, su personalización es prácticamente nula, recomendando los mismos productos a casi la totalidad de usuarias frente al Switch que se basa en el comportamiento de estas para generar una recomendación.

Finalmente, en cuanto a la similaridad de los elementos dentro de una recomendación, se esperaba tener un resultado bajo, con el objetivo de aumentar la diversidad de los productos que se recomiendan. Se puede notar que Wilson Score obtuvo un mejor resultado, pero al interpretarlo se podría determinar que la recomendación del Switch viene dada por la tendencia de compra de ciertos productos de una usuaria (Podría comprar constantemente poleras, por lo que se recomendarán poleras)

Conclusión

Trabajo a Futuro

Se espera una mejora en la consistencia de la información que utiliza Vestuá, estandarizando la forma en que se ingresa esta para poder aumentar la cantidad de usuarias y artículos que se utilizan para el sistema recomendador. Sin mencionar el uso estandarizado de tallas para también agregarlo al content-based RecSys.

Por otro lado se pueden integrar directamente las fotos en el sistema de switch con su modelo de recomendación correspondiente, esto para evitar el uso de ViewTag, que bajo ciertas circunstancias podría tener un comportamiento no esperado.

En cuanto al funcionamiento del Switch, el approach tomado fue el de un switching con reglas manuales basadas en lógica pensada por el equipo. Este se puede mejorar la forma en que se definen las situaciones, trabajando con pesos en el entrenamiento e incluir 2 o más modelos de recomendación para mejorar el rendimiento en las métricas definidas.

Finalmente se pueden incluir métricas de ranking y novedad para mejorar la evaluación del modelo y así ajustar parámetros con mayor precisión.

Pensamientos Finales

Se logró obtener un sistema recomendador con Switch que permite utilizar un modelo de recomendación distinto según la situación lo amerite. Esto podría significar grandes beneficios económicos, reduciendo el tiempo de procesamiento en usuarios que no tienen una cantidad de información que justifique el uso de un sistema recomendador que requiera gran capacidad de cómputo. Este sistema puede ser constantemente mejorado, incluyendo más información y métricas.

Se destaca la mejora obtenida en cuanto al Baseline, utilizado actualmente por la empresa Vestuá, permitiendo demostrar los beneficios de usar distintos modelos recomendadores implementados dentro de un sistema automatizado. Por lo que si se llegara a implementar una estandarización del formato de los productos esta propuesta podría representar un verdadero beneficio para la compañía. Y no sólo esta, si no también otras que se encuentren en la misma situación de stock único.

Referencias

1. <https://retailleader.com/resale-report-factors-driving-market-growth>
2. <https://www.vestua.cl/>
3. <https://www.dlapiper.cl/2022/07/20/dla-piper-chile-asesora-en-el-ingreso-del-gigante-sueco-grupo-hm-a-la-propiedad-de-la-startup-chilena-de-ropa-vestua-el-mercurio/>
4. M.J. Pazzani, D. Billsus, Content Based Recommender Systems, Rutgers University, FX Palo Alto Laboratory
5. <https://vue.ai/products/product-data-platform/>
6. A. Suglia, C. Greco, C. Musto, M. Gemmis, P. Lops, G. Semeraro, A deep architecture for content-based recommendations exploiting recurrent neural networks, in Proceedings of the 25th Conference on User Modeling, Adaptation and Personalization, Jul 2017, pp. 202–211
7. Mustansar Ali Ghazanfar and Adam Prügél-Bennett. An Improved Switching Hybrid Recommender System Using Naive Bayes Classifier and Collaborative Filtering. The 2010 IAENG International Conference on Data Mining and Applications, Hong Kong. 2010.
8. Building Switching Hybrid Recommender System Using Machine Learning Classifiers and Collaborative Filtering. The 2010 IAENG International Conference on Data Mining and Applications, Hong Kong. 2010.